



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

# VISIÓN ARTIFICIAL

CARLOS ANDRÉS MERA BANGUERO, PHD

[carlosmera@itm.edu.co](mailto:carlosmera@itm.edu.co)






PROGRAMA DE INGENIERÍA DE SISTEMAS


[www.itm.edu.co](http://www.itm.edu.co)

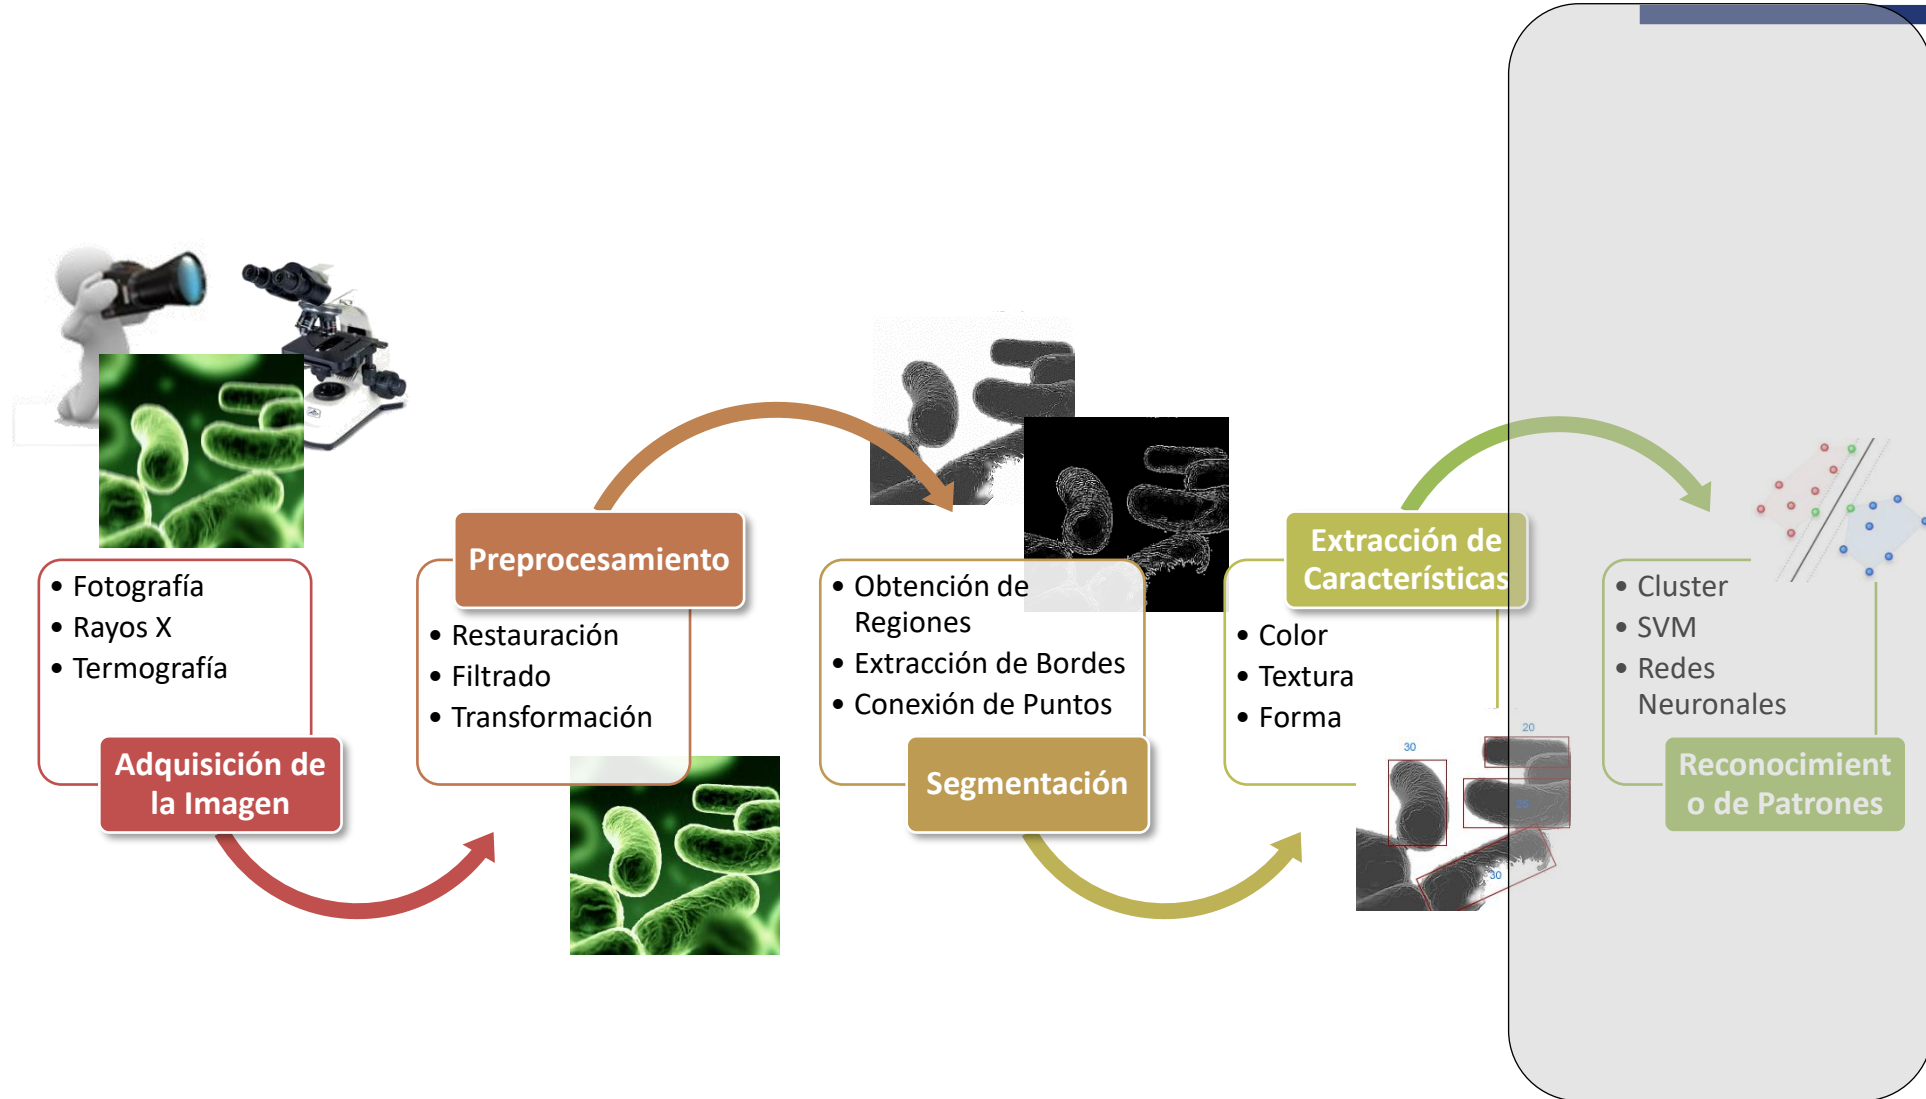
## CLASIFICACIÓN Y RECONOCIMIENTO DE PATRONES


### Introducción

### Métodos Supervisados y no Supervisados

-  KNN
-  Clustering
-  Redes Neuronales
-  Máquinas de Vectores de Soporte (SVM)
-  Ensamblajes de Clasificadores





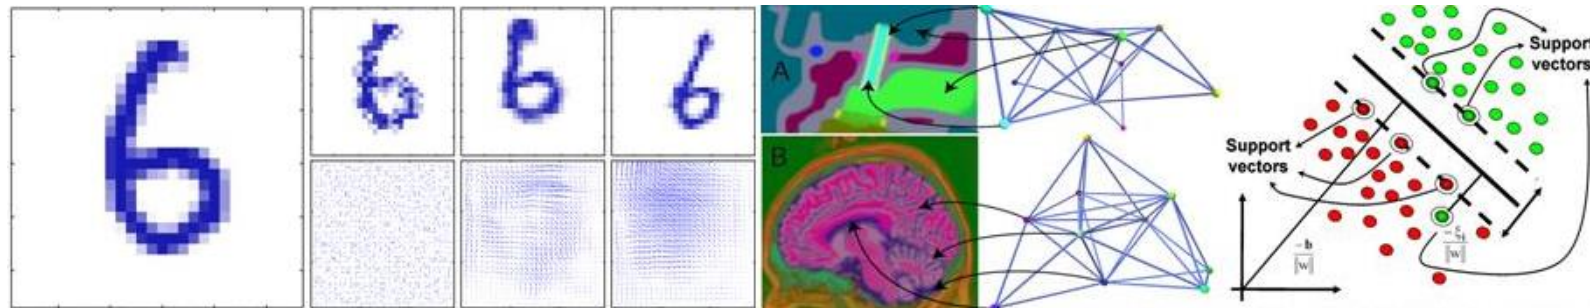


## RECONOCIMIENTO DE PATRONES



## INTRODUCCIÓN

- El *Reconocimiento de Patrones* es la última etapa dentro de un sistema de visión artificial, en la que a partir de las características encontradas, los posibles objetos se **CLASIFICAN** en dos o más clases.



- Clasificar** (o reconocer) significa, en este contexto, asociar a clases (o prototipos) una serie de elementos (u objetos). Esta asociación se realiza en base a las características o propiedades de los objetos.



## CONSIDERACIONES

Las características de las regiones u objetos segmentados se representan usando **vectores de características** normalizados.

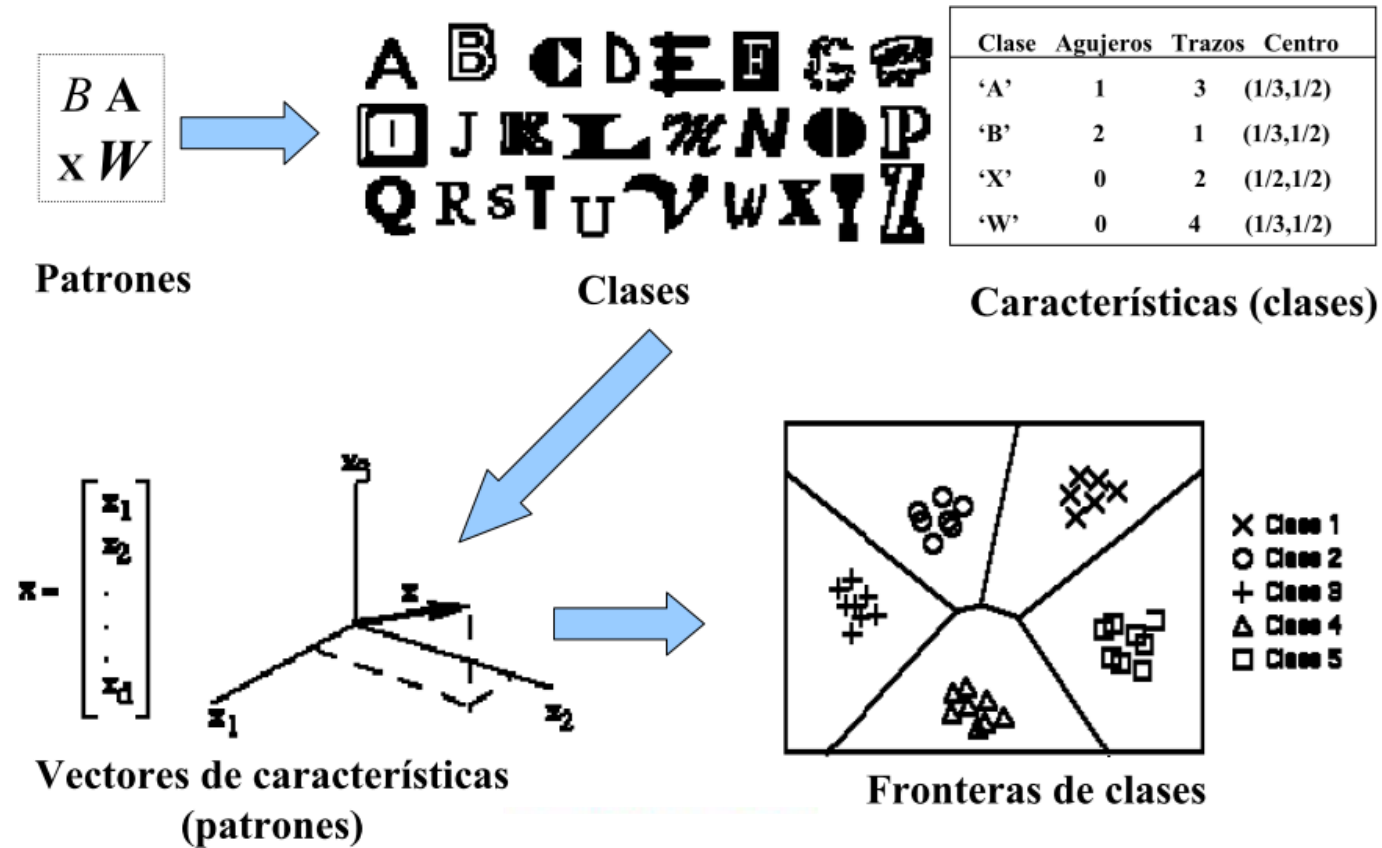
Las características usadas para el reconocimiento deben ser cuidadosamente seleccionadas (p. ej. elección de características invariantes a transformaciones geométricas)

Reconocer o clasificar no son tareas fáciles: las clases pueden no estar correctamente definidas, la información sobre los objetos a clasificar puede ser incompleta.

La interpretación de imágenes (o escenas) requiere el uso de modelos y técnicas de **Inteligencia Artificial**

Métodos de clasificación diferentes → clasificaciones diferentes.

## 🏆 EJEMPLO DE RECONOCIMIENTO DE CARACTERES



✂ **IMPORTANTE:** Si los descriptores elegidos son adecuados, objetos similares tendrán patrones próximos en el espacio de características.



- Patrones que describen objetos de una misma clase, presentan características similares.
- Patrones que describen objetos de diferentes clases presentan características diferenciadas.

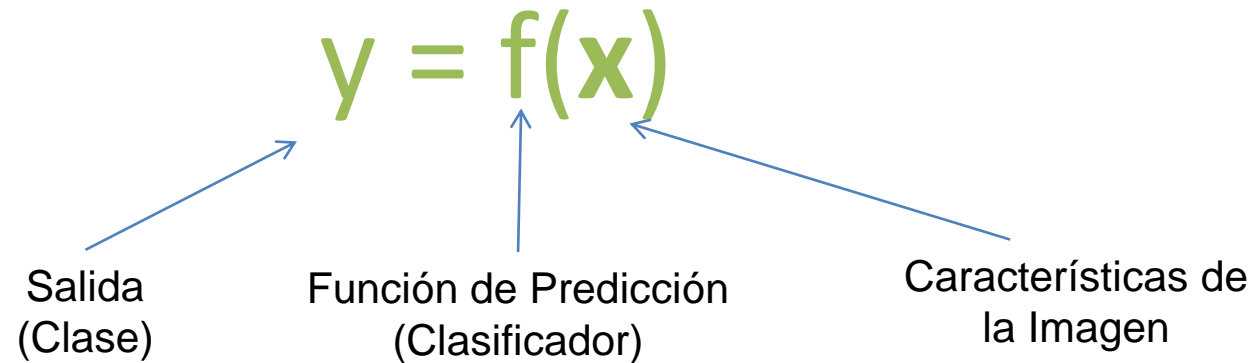


## MODELO GENERAL DE UN CLASIFICADOR

- Aplicar una función de predicción en una representación de las características de la imagen para obtener el resultado deseado


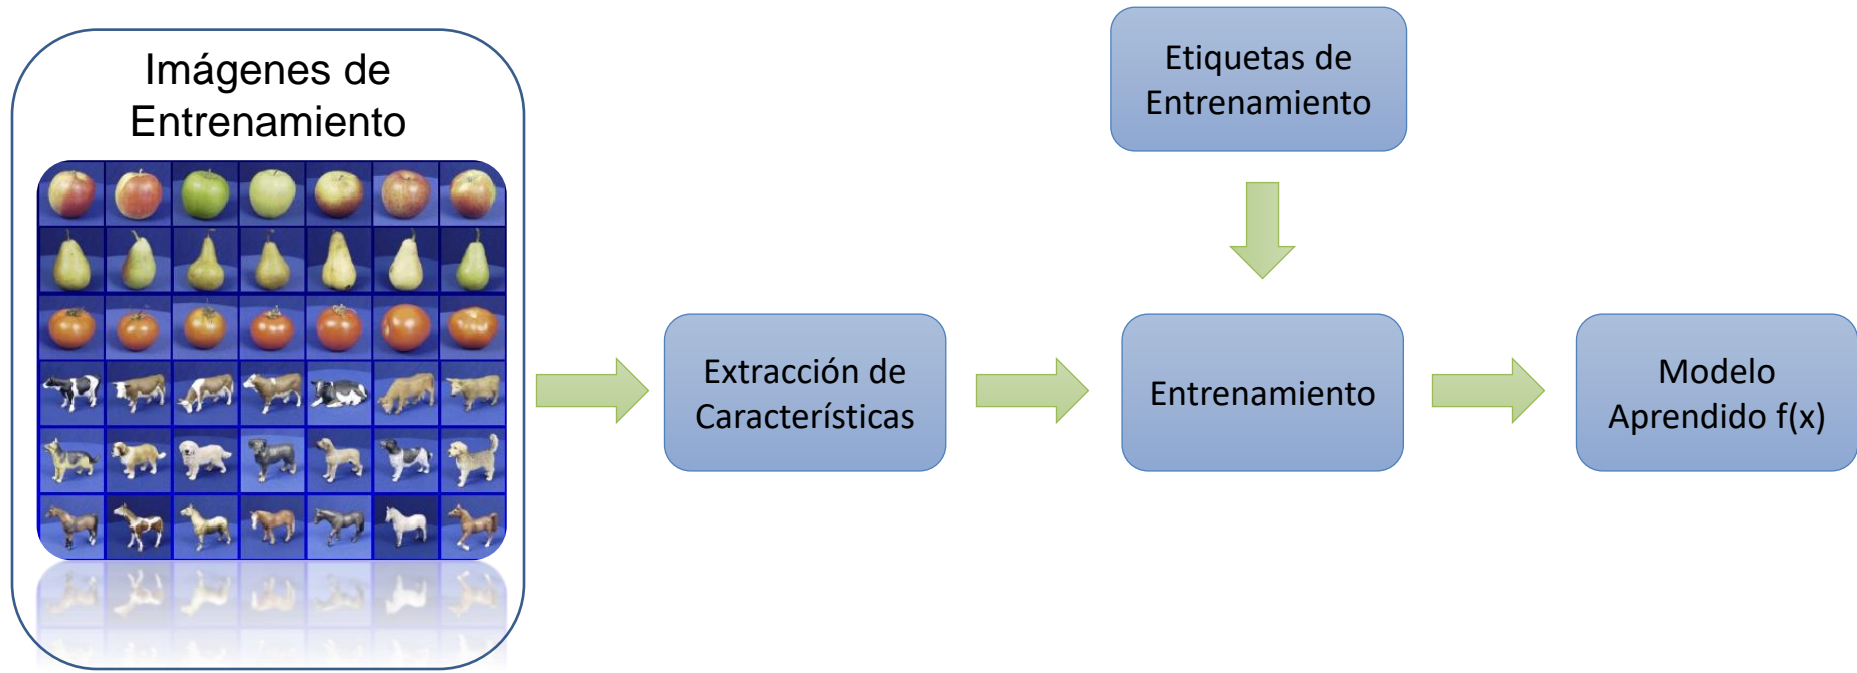
$$f(\text{manzana}) = \text{"manzana"}$$

$$f(\text{vaca}) = \text{"vaca"}$$







- Entrenamiento:** dado un conjunto de ejemplos  $\{(x_1, y_1), \dots, (x_n, y_n)\}$ , calcular la predicción de la función  $f$ , **REDUCIENDO AL MÍNIMO EL ERROR DE PREDICCIÓN** en el conjunto de entrenamiento

## 🦋 MODELO GENERAL DE UN CLASIFICADOR



## TIPOS DE CLASIFICADORES

-  Atendiendo a la información que se proporciona en el proceso de construcción del clasificador se puede hablar de dos tipos de clasificadores: supervisados y No supervisados:
-  **Clasificadores NO Supervisados:** sin la necesidad de ningún supervisor externo, el clasificador determina las clases que representan los datos de entrenamiento.
-  **Clasificadores Supervisados:** el conjunto de entrenamiento es dividido por el maestro en las diferentes clases ya conocidas en las que se desea clasificar, así el clasificador aprende las características que definen cada clase.




## TÉCNICAS DE RECONOCIMIENTO DE PATRONES



## CLASIFICADORES SUPERVISADOS – TEOREMA DE BAYES

- Usar la teoría de la probabilidad para clasificar el objeto en la clase que tenga mayor probabilidad posteriori

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{p(x)}$$



$P(\omega_i)$  = Probabilidad de que en la población haya un objeto de clase  $\omega_i$

$p(x|\omega_i)$  = Probabilidad de que en la clase  $\omega_i$  se de un vector de características  $x$

$P(\omega_i|x)$  = Probabilidad de que el objeto de vector de características  $x$  pertenezca a la clase  $\omega_i$

$$g(x) = \begin{cases} 1 & \text{si } P(\omega_1|x) > P(\omega_2|x) \\ 2 & \text{en otro caso} \end{cases}$$



## CLASIFICADORES SUPERVISADOS – TEOREMA DE BAYES



Asumiendo que  $p(x|\omega_i) \sim N(\mu_i, \Sigma_i)$  la función discriminante para la clase  $\omega_i$  es:

$$g_i(x) = \ln(p(x|\omega_i)) + \ln(P(\omega_i))$$

Donde,  $p(x|\omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i)\right)$

🌀 **Caso 1:**  $\Sigma_i = \sigma^2 I$  **LDA**

🌀 **Caso 2:**  $\Sigma_i = \Sigma$  **Clasificador con Distancia Mahalanobis al Cuadrado**


🌀 **Caso 3:**  $\Sigma_i = \text{Arbitraria}$  **QDA**

## CLASIFICADORES SUPERVISADOS – K VECINOS MÁS CERCANOS


- La idea básica del método considera la utilización de un conjunto de vecinos para etiquetar el nuevo objeto. Esta regla basa su operación en el supuesto de

considerar a los patrones cercanos, como aquellos que tienen la mayor probabilidad de pertenecer a la misma clase.

Así el algoritmo asigna la etiqueta de clase que tengan la mayoría de los  $k$  – vecinos.




## CLASIFICADORES SUPERVISADOS – K VECINOS MÁS CERCANOS







## CLASIFICADORES SUPERVISADOS – 1 VECINO MÁS CERCANOS



## 🦋 CLASIFICADORES SUPERVISADOS – 3 VECINOS MÁS CERCANOS

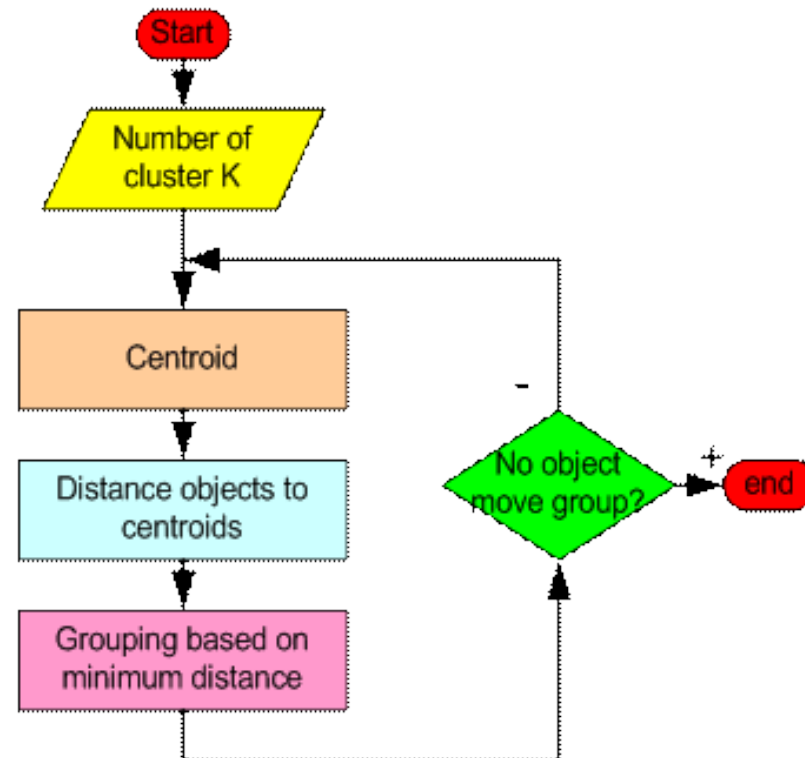


## 🏆 CLASIFICADORES SUPERVISADOS – 5 VECINOS MÁS CERCANOS



## CLASIFICADORES NO SUPERVISADOS - CLUSTERING

- Los algoritmos de **clustering** o agrupamiento intentan **dividir** el conjunto de datos de entrenamiento en **k grupos**, de acuerdo con un criterio de cercanía que se define en términos de una función de distancia, como la Euclidiana, la Manhattan o la de Mahalanobis.





## CLASIFICADORES NO SUPERVISADOS - CLUSTERING

- Cada una de las  $k$  clases se representa con un prototipo ~~o~~ **centroide** que es un vector  $d$ -dimensional:

$$Z_k = \frac{1}{n_k} \sum_{j=1}^{n_k} x_{kj}$$

Siendo:  $x_{kj}$  el  $j$ -ésimo vector de características (patrón) de la clase  $k$ .

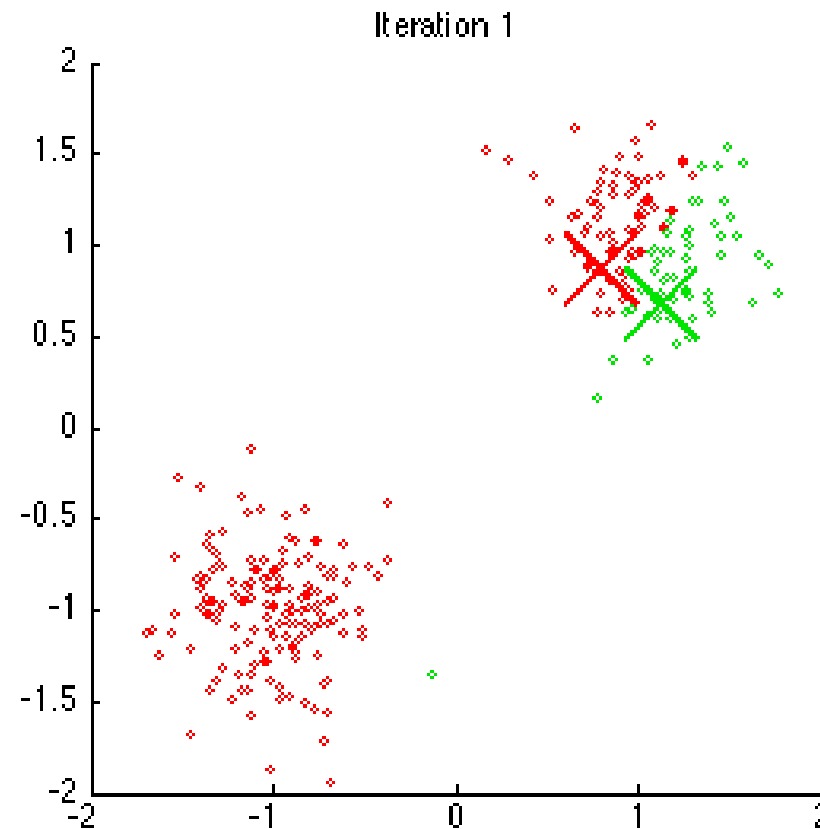
- La distancia euclídeana  $d_E$  de un nuevo patrón  $X$  a la clase  $C_k$  es:

$$d_E(X, Z_k) = \|X - Z_k\| = \sqrt{\sum_{i=1}^d (X_i - Z_{ki})^2}$$

La fórmula anterior es equivalente a evaluar la expresión de la función discriminante de cada clase  $fd_k(X)$ , siendo:  $k \in 1..N$ , para el patrón  $X$  y asignarlo a la clase  $C_k$  para la que  $fd_k(X)$  sea máximo.




## CLASIFICADORES NO SUPERVISADOS - CLUSTERING

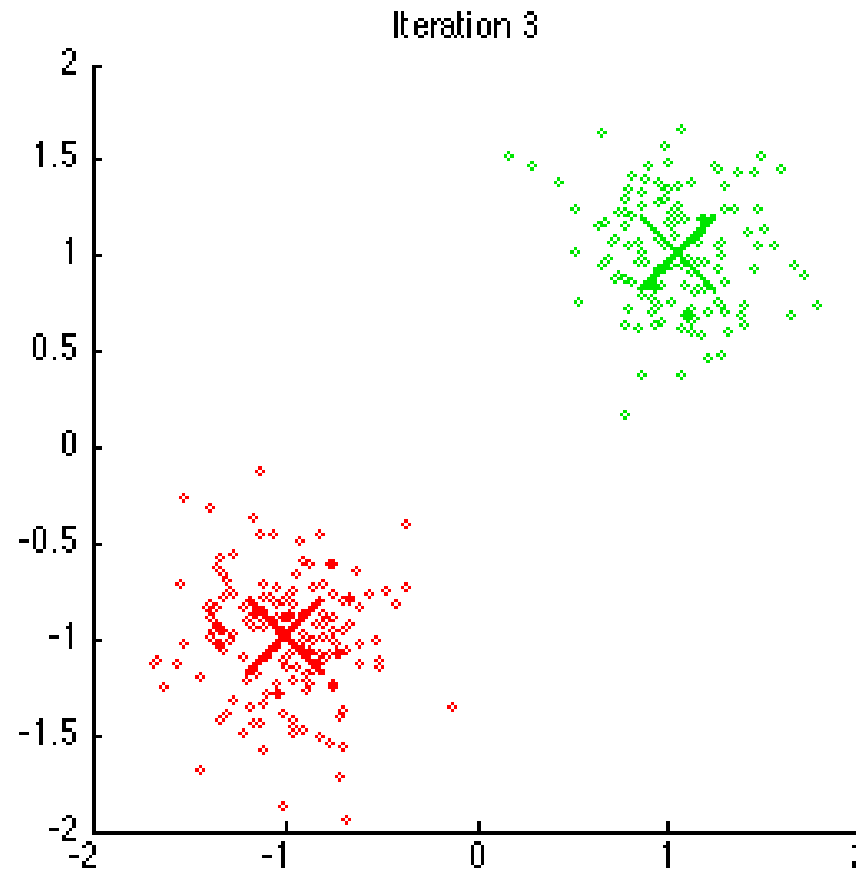




## CLASIFICADORES NO SUPERVISADOS - CLUSTERING




## CLASIFICADORES NO SUPERVISADOS - CLUSTERING



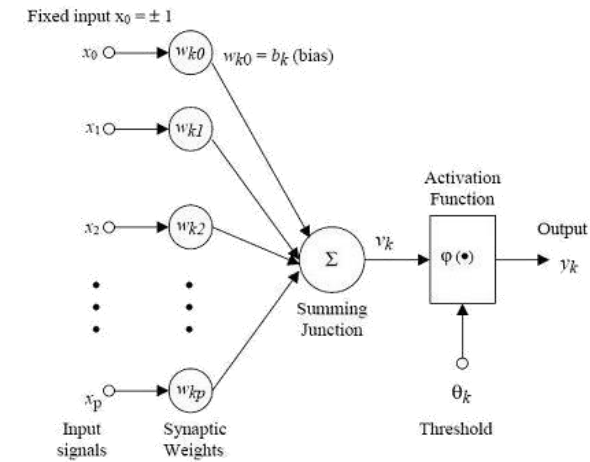



## CLASIFICADORES NO SUPERVISADOS - CLUSTERING



## CLASIFICADORES SUPERVISADOS – REDES NEURONALES

- Por su capacidad de aprendizaje **las neuronas** de los organismos biológicos se han estudiado para su aplicación en sistemas de aprendizaje automático.
- Al igual que las neuronas biológicas están conectadas, las redes de neuronas artificiales están formadas por elementos sencillos de cómputo interconectados según diferentes modelos.



## Neurona artificial

## CLASIFICADORES SUPERVISADOS – REDES NEURONALES

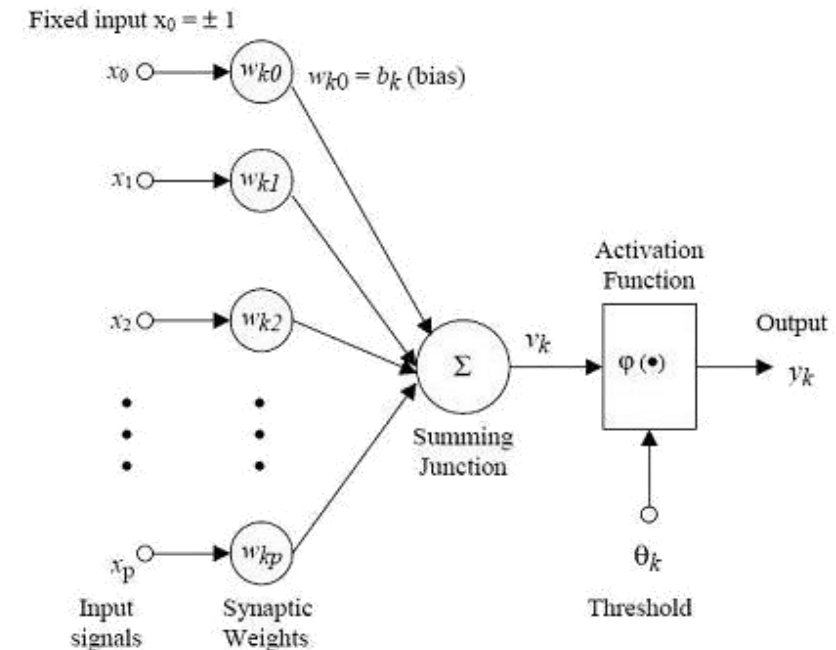
- El **Perceptrón**, en su forma básica, consiste en una neurona que es capaz de aprender una función discriminante lineal  $v_k$ , que permite dividir a dos conjuntos de entrenamiento linealmente separables. Su respuesta consiste en una suma ponderada de sus entradas que representa la ecuación de un hiperplano en el espacio p-dimensional :

$$v_k = \sum_{j=1}^p w_{kj} x_j$$

- A la salida se aplica una función de activación  $\phi(v)$  (escalón, sigmoide, etc) que indica si se activa o no la neurona.


$$\phi(v) = \begin{cases} 1 & \text{if } v \geq 0 \\ 0 & \text{if } v < 0 \end{cases}$$

$$\phi(v) = \tanh\left(\frac{v}{2}\right) = \frac{1 - \exp(-v)}{1 + \exp(-v)}$$


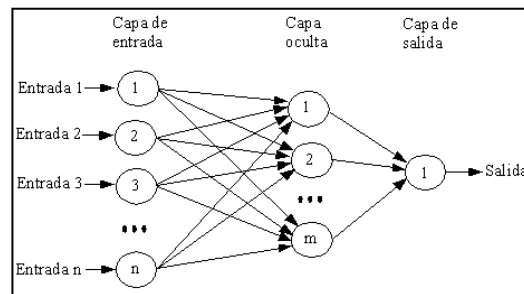


## CLASIFICADORES SUPERVISADOS – REDES NEURONALES

**Perceptrón:** Separación de dos clases (regiones) con un perceptrón:



**Perceptrón de dos capas (multicapa) y ejemplo de frontera de decisión realizable con esta red:**





Una vez una vez entrenada la red con un conjunto de patrones de entrenamiento, ésta es capaz de resolver el problema para patrones

desconocidos.


## CLASIFICADORES SUPERVISADOS – MÁQUINAS DE VECTORES SOPORTE

- Las **SVM** son un tipo de clasificadores de patrones basados en técnicas estadísticas de aprendizaje y están a la cabeza de los métodos de clasificación por permitir construir fronteras de decisión flexibles, y su buena capacidad de generalización.



## CLASIFICADORES SUPERVISADOS – MÁQUINAS DE VECTORES SOPORTE


Clasificación Lineal: Las SVM generan un hiperplano que separa el espacio en dos o más regiones, una para cada clase.





## CLASIFICADORES SUPERVISADOS – MÁQUINAS DE VECTORES SOPORTE

- La **Clasificación NO Lineal** con una SVM realiza una transformación del espacio de entrada a otro de dimensión más alta, en el que los datos son separables linealmente.



Lineal:  $K(x_i, x_j) = x_i \cdot x_j$

Polinómico:  $K(x_i, x_j) = (x_i \cdot x_j + 1)^d$

Gausiano:  $K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$

- Al introducir un kernel, los parámetros  $\alpha$  del vector  $w$  se han así:

$$\tilde{L}(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j)$$



Institución  
**Universitaria**  
Reacreditada en Alta Calidad

¡Gracias!

Hacia una era de  
**Universidad y**  
*Humanidad*



Alcaldía de Medellín